

# 基于多维语言学特征工程的可解释 AIGC 检测：HC3 语料深度分析

杨意翀、韦嘉豪、熊佳漩、曾子致、江易明

南方科技大学

## ABSTRACT

随着 ChatGPT 等大语言模型 (LLM) 的快速普及, 学术抄袭与虚假信息传播风险显著上升。本文围绕“人类文本与 AI 生成文本 (AIGC) 如何区分”这一问题, 基于 Human ChatGPT Comparison Corpus (HC3) 构建中英文双语可解释检测方案。我们不依赖黑盒深度模型, 而是采用多维语言学特征工程: 从词汇丰富度、可读性、词性与句法、依存深度、话语连接与情感情绪六大维度提取每种语言 46–51 个手工特征。通过皮尔逊相关性过滤 ( $|r| > 0.85$ ) 去除冗余后, 训练并比较 Random Forest、XGBoost、LightGBM 三类集成树模型。同时结合 SHAP 与多模型特征重要性共识解释模型决策。实验结果表明, 仅用手工特征即可在英文上达到 **95.1%** 准确率 /  $F1=0.9506$  ( $AUC=0.9898$ ), 在中文上达到 **92.1%** 准确率 /  $F1=0.9199$  ( $AUC=0.9779$ )。归因分析显示, 二元词组重复、句法复杂度与词汇密度是最稳定、最具判别力的 AIGC 语言指纹。

## KEYWORDS

AIGC 检测, 特征工程, 可解释机器学习, SHAP, HC3, ChatGPT, 文本挖掘

### ACM Reference Format:

杨意翀、韦嘉豪、熊佳漩、曾子致、江易明. 2026. 基于多维语言学特征工程的可解释 AIGC 检测: HC3 语料深度分析. In Proceedings of Data Mining Course Final Project (CS306 DM Project). ACM, New York, NY, USA, ?? pages.

## 1 引言

自 2022 年 11 月公开发布以来, ChatGPT 展现出在几乎所有领域生成流畅、连贯文本的能力, 打破了“高质量写作仅属于人类”的传统认知。这一能力在提升生产效率的同时, 也带来了显著风险: 学术不端、规模化虚假信息生成, 以及数字内容可信度下降 [?]。

现有 AIGC 检测方法大体可分为两类: 神经网络检测器通过在标注语料上微调预训练语言模型 (如 RoBERTa、DeBERTa) 获得接近上限的精度, 但可解释性弱、计算成本高, 且对领域迁移较敏感; 统计/零样本方法 (如 DetectGPT [?], GLTR [?]) 依赖生成模型概率扰动信号, 通常需要对 LLM 的白盒访问。

我们认为, 上述两类方法都难以同时满足实际应用对 (a) 准确性、(b) 可解释性、(c) 模型无关性的要求。因此本文采用“特征工程优先”的路线, 系统挖掘区分人类文本与 AI 文本的统计与语言学规律。

主要贡献.

- (1) 我们构建了覆盖中英文的双语特征空间: 每种语言提取 46–51 个语言学特征, 并按六个可解释类别组织。
- (2) 我们验证了基于该特征空间训练的集成树模型在 HC3 上可达到 92–95% 的准确率, 在保持可解释性的同时接近神经网络方法表现。

- (3) 我们给出了 HC3 上的 SHAP 归因分析, 定量刻画“哪些特征组合最能暴露 AI 文本”, 并通过三种模型的一致性排序进行交叉验证。

## 2 相关工作

HC3 与语言学分析. Guo 等 [?] 提出 HC3 数据集, 并从语言学角度比较了人类与 ChatGPT 回答, 指出 ChatGPT 回答通常更长、情绪更中性、连接词更丰富。其微调 RoBERTa 检测器在英文上达到约 98.8%  $F1$ , 但缺乏可解释性。

统计/零样本检测方法. GLTR [?] 通过可视化 token 排名分布识别机器文本; DetectGPT [?] 通过扰动文本并测量对数概率曲率进行检测, 无需训练数据, 但依赖对 LLM 的访问能力。

文体计量与特征工程检测. 基于文体计量的指标 (如 Type-Token Ratio、Honore’s R、可读性分数) 已长期用于作者归因 [?]. 近期研究将其扩展到 AIGC 检测 [?], 但多数工作集中于英文, 且缺少系统 SHAP 归因。本文将该方向扩展到中英双语并进行完整可解释分析。

## 3 数据集

### 3.1 Human ChatGPT Comparison Corpus (HC3)

本文使用 HC3 数据集 [?] 作为单一深度分析语料, 覆盖英文子集 (HC3-EN) 与中文子集 (HC3-ZH)。

HC3-EN. 包含 24 322 个问题, 共 58 546 条人类回答 (来源包括 Reddit ELI5、WikiQA、Wikipedia、医疗问答与金融问答), 以及 26 903 条 ChatGPT 回答, 覆盖五个领域切分: reddit\_eli5、open\_qa、wiki\_csai、medicine、finance。

HC3-ZH. 包含 12 853 个问题、22 259 条人类回答和 17 522 条 ChatGPT 回答, 覆盖七个领域切分: open\_qa、baike、nlppcc\_dbqa、medicine、finance、psychology、law。

### 3.2 预处理与采样

为去除近乎空文本, 过滤长度小于 30 字符 (英文) 或 20 字符 (中文) 的回答。为控制运行成本并保持类别严格平衡, 使用固定随机种子 (42) 在每种语言中分层抽样 10 000 条文本 (5 000 人类、5 000 AI)。最终划分见表 ??。

Table 1: 预处理与分层采样后的数据集统计。

| 划分        | 语言 | 人类   | AI   | 总计   |
|-----------|----|------|------|------|
| 训练集 (80%) | EN | 4000 | 4000 | 8000 |
| 测试集 (20%) | EN | 1000 | 1000 | 2000 |
| 训练集 (80%) | ZH | 4000 | 4000 | 8000 |
| 测试集 (20%) | ZH | 1000 | 1000 | 2000 |

4 特征工程

本文特征空间由六类可解释特征构成。英文文本提取 51 个原始特征，中文文本提取 46 个原始特征，差异来自语言适配策略。

4.1 类别一：词汇丰富度

词汇丰富度用于衡量作者词汇使用的广度。

- **Type-Token Ratio (TTR)**:  $TTR = V/N$ ，其中  $V$  为不重复词数， $N$  为总词数。AI 文本常因模板化表达而呈现更低 TTR。
- **Hapax Legomena Ratio**: 仅出现一次词汇的占比，反映个体化表达程度。
- **Honore's R**:  $R = 100 \cdot \log N / (1 - V_1/V)$ ，其中  $V_1$  为 hapax 数。该指标比 TTR 更强地惩罚词汇复用。
- **Vocabulary Density**:  $V/\sqrt{N}$ ，长度归一化的词汇多样性分数。

中文同时计算词级 (ttr\_word) 与字级 (ttr\_char) TTR，以应对中文分词边界不唯一的问题。

4.2 类别二：可读性

英文采用 textstat 的四项指标:Flesch Reading Ease,Flesch-Kincaid Grade Level、平均词长 (字符) 与平均音节数。中文缺乏成熟音节可读性公式，因此以代理指标替代：平均词长 (字符)、平均句长 (字符)、平均句长 (词数)。

4.3 类别三：词性与句法特征

词性比例可刻画语法风格。英文使用 NLTK 平均感知机标注器计算 8 类词性比例 (名词、动词、形容词、副词、连词、限定词、标点、代词)。中文使用 jieba 隐马尔可夫词性标注，并映射到对应类别 (名词 n/nr/ns/nt/nz，动词 v/vd/vn 等)。

此外，英文文本进一步使用 spaCy 依存句法分析器提取 5 个依存树深度特征：最大深度、平均深度、深度标准差、深层子句比例 (depth > 5)、平均分支因子。这些特征用于刻画层级嵌套复杂度，在英文 AI 文本中尤为显著。

4.4 类别四：话语结构 (连接词)

我们假设 AI 文本更倾向于使用结构化话语标记。据此定义 7 类连接词 (表 ??)，并计算每百词归一化频率。同时计算总体连接密度与结构化标记比 (顺序类 + 总结类)。

Table 2: 连接词子类别与示例。

| 类别    | 示例 (英文)                                     |
|-------|---------------------------------------------|
| 顺序推进类 | firstly, secondly, finally                  |
| 总结收束类 | in conclusion, to summarize, overall        |
| 转折对比类 | however, nevertheless, on the other hand    |
| 并列补充类 | moreover, furthermore, in addition          |
| 因果推导类 | therefore, consequently, thus               |
| 举例说明类 | for example, for instance, such as          |
| 缓和限定类 | it is important to note, generally speaking |

4.5 类别五：情感与情绪

英文使用 VADER 计算 compound、neutral、negative、positive 分数。基于固定 18 词情绪词典构建 emotion word ratio。

并在句子级计算 3 项波动特征: fluctuation (句级 compound 标准差)、range (最大值减最小值)、flip ratio (相邻句情绪极性变化比例)。直觉上，人类文本情绪起伏更明显，而 AI 文本往往更“平”。

中文由于不适用 VADER，采用人工整理的正负向词典 (20+18 词) 构造对应比例与波动特征，并补充感叹号、问号比例。

4.6 类别六：文本统计特征

包括长度 (字符/词)、句子数、平均句长、停用词比例、大写比例 (英文)、二元组唯一率、数字比例。中文额外加入四字短语比例以刻画成语等固定表达，该特征在人类正式文本中更常见。

4.7 相关性过滤

为降低多重共线性并压缩维度，在训练集上计算特征两两 Pearson 相关矩阵，对  $|r|>0.85$  的特征对移除其中一个，并保留方差更高者。该步骤将英文特征从 51 降至 42，中文从 46 降至 40 (见表 ??)。

Table 3: 相关性过滤移除特征 ( $|r|>0.85$ )。

| 语言     | 移除特征                                                                                                                                                   |
|--------|--------------------------------------------------------------------------------------------------------------------------------------------------------|
| 英文 (9) | sentence_count, ttr, avg_syllables_per_word, flesch_kincaid_grade, avg_sent_len, sentiment_fluctuation, trans_sequential, text_len_words, avg_para_len |
| 中文 (6) | avg_sent_len, sentiment_fluctuation, trans_sequential, text_len_words, avg_sent_len_words, ttr_word                                                    |

5 实验设置

5.1 模型设置

本文训练三类集成树分类器：

**Random Forest (RF)**: 树数量 200，最大深度 15，叶节点最小样本数 10，并行训练。

**XGBoost**: 训练轮数 200，最大深度 6，学习率 0.1，样本与特征子采样比例均为 0.8，评价损失为 log-loss。

**LightGBM**: 训练轮数 200，最大深度 8，学习率 0.1，样本与特征子采样比例均为 0.8。

训练前使用 StandardScaler 对所有特征做零均值、单位方差标准化。所有实验统一采用 80/20 分层训练-测试划分 (random state = 42)。此外在训练集上报告 LightGBM (100 轮) 的 5 折分层交叉验证 F1，用于评估稳定性。

5.2 评价指标

评价指标包括 Accuracy、Precision、Recall、F1-Score (双类别宏平均) 与 ROC-AUC。

6 实验结果

6.1 HC3 英文子集

表 ??给出三种模型在测试集上的表现。XGBoost 取得最佳结果: 95.1% Accuracy、F1 = 0.9506、AUC = 0.9898。LightGBM

略低，但 5 折交叉验证平均 F1 为 0.9394 ( $\pm 0.0040$ )，说明结果稳定而非偶然划分导致。

Table 4: HC3-EN 测试集结果 (2000 样本)。

| 模型                                                  | 准确率           | 精确率           | 召回率           | F1            | AUC           |
|-----------------------------------------------------|---------------|---------------|---------------|---------------|---------------|
| Random Forest                                       | 0.9300        | 0.9479        | 0.9100        | 0.9286        | 0.9798        |
| XGBoost                                             | <b>0.9510</b> | <b>0.9583</b> | 0.9430        | <b>0.9506</b> | <b>0.9898</b> |
| LightGBM                                            | 0.9490        | 0.9554        | <b>0.9420</b> | 0.9486        | 0.9887        |
| 5-Fold CV (LightGBM): mean F1 = 0.9394 $\pm$ 0.0040 |               |               |               |               |               |

6.2 HC3 中文子集

中文结果 (表 ??) 整体略低，说明中文语义歧义与表达多样性带来更高检测难度。LightGBM 略优于 XGBoost，达到 **92.1%** Accuracy、F1 = 0.9199、AUC = 0.9779；其 5 折交叉验证平均 F1 为 0.9165 ( $\pm 0.0056$ )，同样稳定。

Table 5: HC3-ZH 测试集结果 (2000 样本)。

| 模型                                                  | 准确率           | 精确率           | 召回率    | F1            | AUC    |
|-----------------------------------------------------|---------------|---------------|--------|---------------|--------|
| Random Forest                                       | 0.9000        | 0.9049        | 0.8940 | 0.8994        | 0.9665 |
| XGBoost                                             | 0.9200        | 0.9242        | 0.9150 | 0.9196        | 0.9782 |
| LightGBM                                            | <b>0.9205</b> | <b>0.9269</b> | 0.9130 | <b>0.9199</b> | 0.9779 |
| 5-Fold CV (LightGBM): mean F1 = 0.9165 $\pm$ 0.0056 |               |               |        |               |        |

6.3 跨语言对比

从结果看，英文更容易被准确检测：XGBoost 在英文上达到 95.1%，而中文为 92.1%。可能原因之一是英文额外使用了依存句法特征 (仅 EN 可用 spaCy)，该特征组贡献 13.3% 的 SHAP 重要性；中文则依赖更细粒度的 jieba 词性体系与字级特征进行补偿。

7 SHAP 归因分析

7.1 SHAP 重要特征排序

我们对 XGBoost 模型使用 TreeExplainer [?], 在测试集 500 条样本子集上计算 SHAP 值。表 ?? 与表 ?? 给出按平均 |SHAP| 排序的前 10 个特征，并标注其对 “AI” 类概率的影响方向。

Table 6: HC3-EN (XGBoost) SHAP Top-10 特征。

| 排名 | 特征                  | SHAP   | 方向                  |
|----|---------------------|--------|---------------------|
| 1  | unique_bigram_ratio | 1.4193 | AI 中升高 $\uparrow$   |
| 2  | dep_depth_avg       | 0.7910 | AI 中升高 $\uparrow$   |
| 3  | hapax_ratio         | 0.6410 | AI 中降低 $\downarrow$ |
| 4  | adv_ratio           | 0.6175 | AI 中降低 $\downarrow$ |
| 5  | vocab_density       | 0.5275 | AI 中降低 $\downarrow$ |
| 6  | text_len_chars      | 0.5098 | AI 中降低 $\downarrow$ |
| 7  | stopword_ratio      | 0.4575 | AI 中降低 $\downarrow$ |
| 8  | sent_len_cv         | 0.4020 | AI 中降低 $\downarrow$ |
| 9  | punct_ratio         | 0.3110 | AI 中降低 $\downarrow$ |
| 10 | paragraph_count     | 0.2871 | AI 中升高 $\uparrow$   |

Table 7: HC3-ZH (XGBoost) SHAP Top-10 特征。

| 排名 | 特征                  | SHAP   | 方向                  |
|----|---------------------|--------|---------------------|
| 1  | unique_bigram_ratio | 0.7501 | AI 中升高 $\uparrow$   |
| 2  | vocab_density       | 0.6175 | AI 中降低 $\downarrow$ |
| 3  | adv_ratio_zh        | 0.6094 | AI 中降低 $\downarrow$ |
| 4  | pronoun_ratio_zh    | 0.5669 | AI 中升高 $\uparrow$   |
| 5  | sent_len_cv         | 0.5117 | AI 中降低 $\downarrow$ |
| 6  | conj_ratio_zh       | 0.4234 | AI 中升高 $\uparrow$   |
| 7  | honore_r            | 0.4022 | AI 中降低 $\downarrow$ |
| 8  | trans_hedging       | 0.3764 | AI 中升高 $\uparrow$   |
| 9  | avg_para_len        | 0.3322 | AI 中升高 $\uparrow$   |
| 10 | avg_word_len_chars  | 0.3258 | AI 中降低 $\downarrow$ |

7.2 特征组重要性

表 ?? 按六类特征汇总 SHAP 贡献。英文中 Text Statistics 占比最高 (26.6%)，其后为 POS & Syntax (18.1%) 与 Dependency Depth (13.3%)；中文中 POS & Syntax 占比最高 (26.7%)，体现了 jieba 词性体系在中文检测中的区分能力。

Table 8: 特征组 SHAP 贡献占比。

| 特征组                 | EN (%) | ZH (%) |
|---------------------|--------|--------|
| Text Statistics     | 26.6   | 19.1   |
| POS & Syntax        | 18.1   | 26.7   |
| Dependency Depth    | 13.3   | —      |
| Vocabulary Richness | 11.3   | 15.9   |
| Sentence Structure  | 9.8    | 18.0   |
| Transition Words    | 8.8    | 8.5    |
| Sentiment & Emotion | 6.9    | 5.0    |
| Readability         | 5.2    | 6.8    |

7.3 多模型特征重要性共识

为验证 SHAP 结果是否依赖单一模型，我们在三种模型上均使用 impurity-based 重要性排序，并以排名和 (越低越好) 作为共识分数。表 ?? 给出英文前 7 个共识特征。三种模型均将 unique\_bigram\_ratio 排名第一 (★★★)，进一步证明其诊断价值。

Table 9: 多模型共识 (HC3-EN)。★★★ 表示最高共识等级。

| 特征                  | RF | XGB | LGB | 等级  |
|---------------------|----|-----|-----|-----|
| unique_bigram_ratio | 1  | 1   | 1   | ★★★ |
| dep_depth_avg       | 3  | 2   | 4   | ★★★ |
| text_len_chars      | 5  | 6   | 3   | ★★★ |
| hapax_ratio         | 2  | 3   | 9   | ★★★ |
| vocab_density       | 7  | 8   | 6   | ★★  |
| sent_len_cv         | 10 | 9   | 2   | ★★  |
| adv_ratio           | 8  | 12  | 11  | ★★  |

8 关键发现与讨论

发现 1: 二元词组重复是通用 AI 指纹。unique\_bigram\_ratio 在中英文中均位列 SHAP 第一，且在多模型共识中属于最

高等级特征。这表明 ChatGPT 在多领域文本中更容易产生重复、模板化的词对组合。

发现 2: 英文中句法复杂度具有显著区分力。英文中 `dep_depth_avg` 排名第二, 贡献 13.3% 特征组 SHAP。AI 英文文本常表现出更深的从句嵌套层级, 与 ChatGPT 强调“完整性与结构化表达”的生成倾向一致。

发现 3: 中文检测主要由词性分布驱动。中文 POS & Syntax 特征组贡献达 26.7%。人类文本更常使用副词 (`adv_ratio_zh` 在 AI 中下降), 体现口语化缓和与情绪增强; AI 文本则更常使用连词 (`conj_ratio_zh` 在 AI 中升高) 以强化显式逻辑。

发现 4: AI 文本词汇多样性持续偏低。 `hapax_ratio` 与 `vocab_density` 在中英文中都与 AI 类负相关。尽管 ChatGPT 拥有大规模训练词汇, 其单篇输出仍倾向于收敛到高概率、领域常见词, 导致局部词汇集合更受限。

发现 5: 人类文本句长波动更大。 `sent_len_cv` 在 AI 文本中普遍更低, 说明 ChatGPT 更倾向于生成长度均匀的句子, 这是“机器化文风”的另一种表现。

发现 6: 连接与话语特征验证 AI 结构化表达倾向。 `trans_hedging` 在中文 SHAP 中排名第 8, 如“值得注意的是”“一般来说”等表达在 AI 文本中更高频。整体上, 连接词特征贡献约 8.5–8.8% SHAP, 虽非最强但稳定有效。

情绪平坦性: 虽被过滤但有效的信号。 `sentiment_fluctuation` 因与其他情感统计高度相关 ( $|r| > 0.85$ ) 在两种语言中被移除。但 `sentiment_neutrality` 保留并对分类有贡献, 支持“AI 文本情绪变化不足、语气更平”的假设。

与神经网络基线对比。仅依赖手工特征时, 我们在 HC3 上达到 92–95% 准确率。相比 Guo 等报告的微调 RoBERTa (约 98.8% F1) 存在 3–7% 差距, 但换来了完整可解释性: 模型可通过 SHAP 对每次预测给出特征级解释, 并且推理阶段无需 GPU 基础设施。

## 9 结论

本文提出了一种面向 HC3 的中英双语、可解释、特征工程优先的 AIGC 检测流程。通过词汇丰富度、可读性、句法结构、话语连接、情感情绪等维度构建 40–42 个有效特征, 并结合 RF、XGBoost、LightGBM 三类集成树模型实现高精度检测。SHAP 分析定量表明: 二元词组重复、句法层级深度、词汇多样性是识别 AI 文本的核心信号, 且在跨语言、跨模型上具有一致性。

研究结果说明: 在不依赖黑盒深度模型的前提下, 同样可以实现准确且可解释的 AIGC 检测。本文构建的特征体系与归因方法可进一步迁移到新语言、新模型与垂直领域场景。

局限性与未来工作。当前特征尚未显式建模主题与领域分布迁移, 未来应重点评估跨领域泛化能力。此外依存句法特征当前仅用于英文, 若引入中文依存分析器 (如 LTP), 有望缩小约 3% 的性能差距。随着 LLM 持续迭代, 特征阈值与判别边界可能漂移, 因此需要周期性重标定。

## ACKNOWLEDGMENTS

感谢 HC3 数据集贡献者 (Guo 等) 公开语料, 为 AIGC 检测提供了可复现研究基础。

## 参考文献

- [1] Biyang Guo, Xin Zhang, Ziyuan Wang, Minqi Jiang, Jinran Nie, Yuxuan Ding, Jianwei Yue, and Yupeng Wu. How Close is ChatGPT to Human Experts? Comparison Corpus, Evaluation, and Detection. arXiv preprint arXiv:2301.07597, 2023.
- [2] Eric Mitchell, Yoonho Lee, Alexander Khazatsky, Christopher D. Manning, and Chelsea Finn. DetectGPT: Zero-Shot Machine-Generated Text Detection using Probability Curvature. In Proceedings of ICML, 2023.
- [3] Sebastian Gehrmann, Hendrik Strobelt, and Alexander M. Rush. GLTR: Statistical Detection and Visualization of Generated Text. In Proceedings of the ACL Demo Track, 2019.
- [4] Scott M. Lundberg and Su-In Lee. A Unified Approach to Interpreting Model Predictions. In Proceedings of NeurIPS, 2017.
- [5] Patrick Juola. Authorship Attribution. Foundations and Trends in Information Retrieval, 1(3):233–334, 2006.
- [6] Gaurav Bhatt, Bhavna Jain, and Sanjay Chaudhary. Stylometric Detection of AI-Generated Text in Twitter Timelines. arXiv preprint arXiv:2303.03697, 2023.

**Temporary page!**

ℒ<sub>T</sub> was unable to guess the total number of pages correctly. As there was some unprocessed data that should have been added to the final page this extra page has been added to receive it.

If you rerun the document (without altering it) this surplus page will go away, because ℒ<sub>T</sub> now knows how many pages to expect for this document.